

作业四：各组作业三数据探索与分析报告

组号: 27

数据来源: 远端 MySQL (10.60.254.44:3306/hw4) → student.csv / course.csv / sc.csv

分析工具: Python (pandas, scikit-learn, xgboost, matplotlib, seaborn)

小组成员:

- 231250108 李孝胤
- 231250125 沈红旗
- 231250033 戴志洋
- 231250016 孙子然
- 231250075 郭炳辰
- 231250110 尚昊毅

一、数据概览

表	总行数	组数	本组(27)行数	本组院系分布
student	3,929	26	150	A:50, B:50, C:50
course	1,022	25	30	A:10, B:10, C:10
sc	22,287	25	751	A:250, B:250, C:251

各组基本统计量:

指标	均值	标准差	最小值	中位数	最大值
学生数	157.1	46.3	100	150	374
课程数	40.9	56.5	10	30	300+
选课数	891.5	807.6	250	750	4800+
男生比例	0.34	0.23	0.00	0.50	0.57
人均选课	5.31	1.55	5.00	5.00	12.75
平均成绩	61.2	32.0	0.0	77.9	84.9

二、本组(27)数据特征

整体特征 vs 全量均值

指标	本组	全量均值±标准差	Z-SCORE	判定
学生数	150	157.1±46.3	-0.15	正常
男生比例	0.44	0.34±0.23	+0.44	正常
专业数	9	7.5±6.8	+0.22	正常
课程数	30	40.9±56.5	-0.19	正常
共享率	0.47	0.23±0.31	+0.75	正常
选课数	751	891.5±807.6	-0.17	正常
人均选课	5.01	5.31±1.55	-0.20	正常
平均成绩	78.66	61.18±31.97	+0.55	正常

结论: 本组在所有维度上均无异常，数据规范完整。

院系级明细

院系	学生	男生比	专业数	课程	共享率	选课	均分
A	50	50.0%	8	10	0%	250	78.7±11.4
B	50	50.0%	8	10	70%	250	78.8±11.2
C	50	32.0%	4	10	70%	251	78.5±11.8

发现: 院系C男生仅32%，低于A/B的50%；院系C仅4专业，少于A/B的8专业。三院系成绩分布高度一致（均分78.5~78.8）。

三、异常检测

方法

对各组特征计算 z-score， $|z| > 2$ 判定为异常。

异常组清单

组号	异常指标	具体情况
2	学生数、课程数、人均选课	学生374人 (2.4 σ)，课程300+，人均12.75门——疑似多轮重复上传
5	平均成绩	成绩 0.0 —— 选课表score字段全为空
12	平均成绩	成绩 0.0 —— 同上
22	平均成绩	成绩 0.0 —— 同上

组号	异常指标	具体情况
28	平均成绩	成绩 0.0 —— 同上
25	共享率、院系缺失	共享率异常 + student表缺院系 + sc表缺院系

院系完整性

表	缺院系的组
student	25, 221250099
course	全部完整
sc	25

四、可视化图表

图1: 各组概览（6维对比）




六张子图分别展示各组的学生数、课程数、选课数、男生比例、平均成绩、成绩分布。红线为标准值，绿线为本组(27)。

观察:

- 大多数组数据量在150/30/750左右，符合作业规范
- 组2在所有维度显著偏离
- 本组成绩中上水平（78.7），处于前40%

图2: 散点图矩阵



四个关键散点图：学生数-选课数（高度线性相关）、男生比-均分、共享率-人均选课、课程数-均分。

观察：

- 学生数与选课数几乎成完美线性关系（ $r \approx 1.0$ ），每学生固定5门课
- 本组位于男女生均衡、成绩中上的区域


图3: 相关性热力图



各特征间相关性：

- stu_cnt ↔ sc_cnt: 强正相关（0.99），符合每人5门课
- share_ratio ↔ sc_per_stu: 中等正相关，高共享组人均选课更多
- male_ratio ↔ avg_score: 弱相关

图4: 决策树可视化



将各组按成绩中位数分为"高分组"/"低分组"，构建决策树分类模型。

五、组间相似度分析

余弦相似度 Top5

排名	组号	相似度
1	7	0.9709
2	23	0.8894
3	18	0.8015
4	3	0.6670
5	25	0.6099

欧氏距离 Top5

排名	组号	距离
1	7	0.5771
2	3	0.9999
3	18	1.0300
4	23	1.2035

排名	组号	距离
5	17	1.4981

结论: 组7与本组最为相似（余弦0.971，欧氏0.577），两组数据特征高度一致。

层次聚类

采用 Ward 链接法，将所有组分为4类：

类别	组成员	特征
第1类	大部分常规组	标准数据量，均值附近
第2类	3, 7, 16, 18, 23, 25, 27	共享率高，成绩中上
第3类	2	数据量异常大
第4类	5, 12, 22, 28	成绩为0

结论: 本组(27)属于第2类，与组3、7、16、18、23、25具有相似的数据特征，特点是共享课程比例较高、成绩处于中上水平。

六、分类模型

决策树

指标	值
交叉验证准确率	48.0%
最大深度	3

特征重要性：

特征	重要性
share_ratio（共享率）	0.4031
sc_per_stu（人均选课）	0.3870
major_cnt（专业数）	0.2099
stu_cnt / male_ratio / cou_cnt	0.0000

XGBoost

指标	值
交叉验证准确率	40.0%
n_estimators	100

特征重要性：

特征	重要性
sc_per_stu（人均选课）	0.4582
major_cnt（专业数）	0.3466
male_ratio（男生比例）	0.1032
share_ratio（共享率）	0.0920

说明: 准确率偏低是因为仅有25个样本（25组），机器学习模型需要更多数据才能有效。但特征重要性分析仍然有价值——人均选课数和专业数是区分组间差异的最关键特征。

七、结论与建议

关于本组数据

- 1. 数据质量优秀: 150/30/751完全符合作业规范，z-score均小于1，无异常
- 2. 三院系统性: A/B两院男女均衡(~50%)，C院男生偏少(32%)——符合C系统原始生成逻辑
- 3. 成绩水平: 均分78.7，处于全量前40%，选课数据生成质量好

关于其他组

- 1. 组2: 数据量巨大（374学生），疑似包含多轮测试数据或重复上传，建议清理
- 2. 组5/12/22/28: score字段全为空或为0，选课表可能未正确填入成绩数据
- 3. 组25: 部分院系数据缺失，上传可能不完整
- 4. 组7: 与本组数据特征最接近，共享率高且成绩中上

方法局限性

- 仅25组样本，分类模型准确率有限
- 未考虑课程名/专业名的文本相似度
- 成绩分布可能存在各组生成策略差异（随机种子、分数范围等）